

The Recommendation Process

1.1 INTRODUCTION

RS = Recommendation System

Netflix prize 2006

$\mathcal{U} = \{u_1, \dots, u_M\}$ users $\left(\begin{matrix} M \gg N \gg 1 \\ \text{2178} \end{matrix} \right)$

$\mathcal{I} = \{i_1, \dots, i_N\}$ items

$R \in \mathbb{R}^{M \times N}$ - matrix of ratings r_i^u

$r_i^u \in \mathcal{V} = \{0, \dots, V\}$, (u, i) pairs

$R \in \mathcal{V}^{M \times N}$

0 - no rating, V - max rating

(ON CAN RATING) \bar{r}_R - average rating

and R

Denote by $\langle u, i \rangle$ the enumeration of all those dyads in R s.t. $r_i^u > 0$.

Denote by $\langle u, i, r \rangle$ an enumeration of all the explicit ratings.

Denote \mathcal{F} - the whole set of predicates relative to

\mathcal{U}, \mathcal{I} or $\mathcal{U} \times \mathcal{I} \times \mathcal{V}$.

$\mathcal{I}(u) = \mathcal{I}_R(u) = \{i \in \mathcal{I} \mid \langle u, i \rangle \in R\}$

the set of items rated by u

$$\mathcal{U}(i) = \mathcal{U}_R(i) = \{u \in \mathcal{U} \mid \langle u, i \rangle \in R\}$$

הינה רשימת
i של

Active user - any user u s.t. $\mathcal{I}_R(u) \neq \emptyset$
(any user with a rating history)

מכל $\mathcal{U}(I)$ ו- $\mathcal{I}(u)$ - Cold start
. \emptyset פיקטור

אם RS של המשתמש, u active user
אם $\mathcal{L}_u \subseteq \mathcal{I}$ אזי u - Cold start
. $\mathcal{L}_u \cap \mathcal{I}_R(u) = \emptyset$ - אזי

Algorithm 1 Generation of recommendation list.

Require: A number of candidate items, D (positive integer such that $D \leq N$)

Require: The size of the recommendation list, L (positive integer such that $L \leq D$)

- 1: Choose $\mathcal{C} \subseteq \mathcal{I}$, according to a business-specific criterion, such that $|\mathcal{C}| = D$ and $\mathcal{C} \cap \mathcal{I}_R(u) = \emptyset$.
- 2: Associate each item $i \in \mathcal{C}$ with a score p_i^u , which represents the appreciation of u for i
- 3: Let \mathcal{L}_u be the selection of the top L items in \mathcal{C} with the highest values p_i^u
- 4: Return \mathcal{L}_u

1.2.1 EVALUATION

- Online evaluation:

המשתמש רשם דירוגים
RS - רשימת דירוגים
המשתמש

- Offline evaluation:

(Train) T - R דירוגים של המשתמש
(Test) S

Prediction Accuracy

MAE = Mean Absolute Error (widely used)

$$MSE = \frac{1}{|\mathcal{U}(i)|} \sum_{\langle u, i \rangle \in S} (r_i^u - \hat{r}_i^u)^2$$

$$RMSE = \sqrt{MSE}$$

MPE = Mean Prediction Error

$$= \frac{1}{|S|} \sum_{\langle u, i \rangle \in S} \mathbb{1}_{\{r_i^u \neq \hat{r}_i^u\}}$$

Confusion Matrix
and ROC analysis

Recommendation Accuracy

u-ס המצגים המצויים - L_u

u-ס המצגים המצויים - T_u

explicit feedback יש, והמצגים
הם כתוצאה מרשימת המצגים

threshold ϵ - $\{i \in I_s(u) : r_i^u > \epsilon\}$

היכולת של המצגים המצויים להיות
יחידים

$$Recall(L) = \frac{1}{M} \sum_{u \in U} \frac{|L_u \cap T_u|}{|T_u|}$$

$$Precision(L) = \frac{1}{M} \sum_{u \in U} \frac{|L_u \cap T_u|}{|L_u|}$$

F-score - מידה של איכות

$$F = \frac{2 \cdot precision \cdot recall}{precision + recall}$$

Algorithm 2 User satisfaction of user u for item i .

Require: An item $i \in \mathcal{T}_u$

Require: A number of candidate items, D (positive integer such that $D \leq |\mathcal{I}|$)

Require: The size of the recommendation list, L (positive integer such that $L \leq D$)

1: Let \mathcal{C} be a random subset of \mathcal{I} , with size D , whose elements have not been rated by u

2: Add i in \mathcal{C}

3: Assign to each item $i \in \mathcal{C}$ a score p_i^u , which represents the appreciation of u for i

4: Let \mathcal{L}_u be the selection of the L items in \mathcal{C} with the highest values p_i^u

5: **if** $i \in \mathcal{L}_u$ **then**

6: return a *hit*

7: **else**

8: return a *miss*

9: **end if**

$i \in \mathcal{T}_u$ כל דבר הנדרש מן המערכת

$$US\text{-}Recall(u, L) = \frac{\#hits}{|\mathcal{T}_u|}$$

$$US\text{-}Precision(u, L) = \frac{\#hits}{L \cdot |\mathcal{T}_u|} = \frac{\#hits \setminus L}{|\mathcal{T}_u|}$$

1. recall הוא היחס בין מספר הפגמים שבהם $|\mathcal{T}_u| = 1$ למספר הפגמים
0. precision הוא היחס בין מספר הפגמים שבהם $|\mathcal{T}_u| = 1$ למספר הפגמים
המקסימלי

Rank Accuracy

הפרדת המדרגים בין המערכת למשתמש u היא
הפרדת המדרגים בין המערכת למשתמש u היא

$$Kendall's \text{ coef. } K(\tau_u, \hat{\tau}_u) = \frac{2 \left(\sum_{i,j \in \mathcal{I}} \mathbb{1}[\tau_u(i) < \tau_u(j) \wedge \hat{\tau}_u(j) < \hat{\tau}_u(i)] \right)}{N(N-1)} \in [0,1]$$

$$Spearman's \text{ coef. } \rho(\tau_u, \hat{\tau}_u) = \frac{\sum_{i \in \mathcal{I}} (\tau_u(i) - \bar{\tau}_u)(\hat{\tau}_u(i) - \bar{\hat{\tau}}_u)}{\sqrt{\sum_{i \in \mathcal{I}} (\tau_u(i) - \bar{\tau}_u)^2 \sum_{i \in \mathcal{I}} (\hat{\tau}_u(i) - \bar{\hat{\tau}}_u)^2}} \in [-1,1]$$

Some other Evaluation Metrics

Novelty, Serendipity, Diversity, Coverage

Main Challenges in RS

• Sparsity and Cold Start -

גז"ר הספס"ר יב"ר כ- "reduced coverage"
כשנכנסים לרשימה (item) חלשים - cold start
דרכי התמודדות - preference elicitation - מבקשים
מהמשתמש סכר של העדפות כשהוא נכנס
בראשית, למשל.
דרכי נוספת להתמודדות - שהמשתמש גוזר
אחריהם ומוזר של הסרטים כגון סדר
גון פרמיון/מיתוסים חזקים שקיימים.

• Scalability -

סוג
כח"ל $M \gg N$ משמשים
סכן יעילות של קשרי פדיון-כח"ל
ומתן משמשים-משמשים.

• Item Churn

נכנסים מחדש ומשתנים חזקים
זמן של זמן משמשים חזקים
על"מ - ע"ז ג-
incremental model-maintenance
techniques

• User Privacy

• Security

against malicious users
דרכי התמודדות: פרופילינג
attacker profiler.

1.3 RECOMMENDATION AS INFORMATION FILTERING

1.3.1 DEMOGRAPHIC FILTERING

2/1 1/1

1.3.2 CONTENT-BASED FILTERING

, 3/11/11

Minkowski Distance:

$$\text{dist}_p^m(i, j) = \left(\sum_{j=1}^k |w_{i,j} - w_{j,i}|^p \right)^{1/p}$$

Cosine Similarity:

$$\text{sim}^c(i, j) = \frac{w_i^T w_j}{\|w_i\|_2 \cdot \|w_j\|_2} \quad \left(\begin{array}{l} \text{effective in dealing} \\ \text{with sparse feature} \\ \text{vectors} \end{array} \right)$$

Jaccard Similarity:

$$\text{sim}^j(i, j) = \frac{w_i^T w_j}{w_i^T w_i + w_j^T w_j - w_i^T w_j}$$

$$\text{sim}^j(x, -x) = \frac{-\|x\|^2}{\|x\|^2 + \|x\|^2 - (-\|x\|^2)} = -\frac{1}{3} \quad ? \quad \ominus$$

Jaccard similarity exhibits aspects of both the Euclidean and cosine measures. In particular, it tends to behave like the former (resp. the latter) if $\text{sim}^j(i, j) \rightarrow 1$ (resp. if $\text{sim}^j(i, j) \rightarrow 0$).

1.4 COLLABORATIVE FILTERING

The assumption:

Users who adopted the same behaviour in the past will tend to agree also in the future.

Baselines:

$$\text{itemAvg}(i) = \bar{r}_i = \frac{1}{|U(i)|} \sum_{u \in U(i)} r_i^u$$

$$\text{userAvg}(u) = \bar{r}^u = \frac{1}{|I(u)|} \sum_{i \in I(u)} r_i^u$$

$$\text{DoubleCentering}(u, i) = \alpha \bar{r}_i + (1-\alpha) \bar{r}^u$$

↑
weights for items

items baseline $b_i^u - \lambda \mu$

CF Approaches

memory-based

רעיון: מציאת דמיון בין דברים
DB - סדרה

neighborhood-based methods

הצורך בשיטות ממוננות
indexing מיושם למציאת דמיון בין דברים

neighborhood-based methods tend to detect strong but local relationships

model-based

עובד off-line אך עדיין
personalized ריכוז
on-line - הן גורמים
לשינויים

מיושם רעיון ממוננות
interpretable מודל

model-based - אף על פי

dimensionality reduction
למציאת דמיון בין דברים
weak but global relationships

CF

item-based approach

ההנחה: דברים דומים יצאו דמיון גבוה
מבחינת המשתמש

הקבוצה $K = N^K(i; u)$ היא קבוצת הדברים
הדומים ל- i עבור u

$$\hat{r}_i^u = b_i^u + \frac{\sum_{j \in N^K(i; u)} s_{i,j} \cdot (r_j^u - b_j^u)}{\sum_{j \in N^K(i; u)} s_{i,j}}$$

neighborhood-based approaches

(מציאת הדברים הדומים ביותר ל- i)

$$N^K(u) = \{i \mid s_{i,u} > \tau\}$$

הקבוצה $N^K(u)$ היא קבוצת הדברים
הדומים ל- u

עבור u נתון $s_{i,u} = s_{u,i}$

$$\hat{r}_i^u = b_i^u + \frac{\sum_{j \in N^K(u)} s_{i,j} \cdot (r_j^u - b_j^u)}{\sum_{j \in N^K(u)} s_{i,j}}$$

? מודל ממוננות

$$U_R(i, j) \stackrel{\text{def}}{=} U_R(i) \cap U_R(j)$$

$$\text{Pearson}(i, j) \triangleq \frac{\sum_{u \in U_R(i, j)} (r_i^u - \bar{r}_i) \cdot (r_j^u - \bar{r}_j)}{\sqrt{\sum_{u \in U_R(i, j)} (r_i^u - \bar{r}_i)^2} \sqrt{\sum_{u \in U_R(i, j)} (r_j^u - \bar{r}_j)^2}}$$

$$AdjCosine(i, j) \triangleq \frac{\sum_{u \in \mathcal{U}_{\mathbf{R}}(i, j)} (r_i^u - \bar{r}_u) \cdot (r_j^u - \bar{r}_u)}{\sqrt{\sum_{u \in \mathcal{U}_{\mathbf{R}}(i, j)} (r_i^u - \bar{r}_u)^2} \sqrt{\sum_{u \in \mathcal{U}_{\mathbf{R}}(i, j)} (r_j^u - \bar{r}_u)^2}}.$$

הצורה הבאה:

$$r_i^u = \sum_{j \in \mathcal{N}^K(i; u)} w_{i,j} \cdot r_j^u$$

אנחנו רוצים למצוא את ה- $w_{i,j}$

$$\begin{aligned} \min \quad & \sum_{v \in \mathcal{U}_{\mathbf{R}}(i)} \left(r_i^v - \sum_{j \in \mathcal{N}^K(i; u, v)} w_{i,j} \cdot r_j^v \right)^2 \\ \text{s.t.} \quad & w_{i,j} \geq 0 \quad \sum_j w_{i,j} = 1 \quad \forall i, j \in \mathcal{I}. \end{aligned}$$

אנחנו רוצים למצוא את ה- $w_{i,j}$ עבור כל i, j

1.4.2 LATENT FACTOR MODELS

למודל פוטנציאלי של latent factor models


הקשר והקשר

Latent Semantic Indexing = LSI

המטרה היא dimensionality reduction
הקשר והקשר

$$SVD(A^{M \times N}) = U^{M \times M} \Sigma^{M \times N} V^{N \times N^T}$$

$$A \approx U_k \cdot \Sigma_k \cdot V_k^T$$



לכן

$$\min_{A_k \in \mathbb{R}^{M \times N}} \|A - A_k\|_F^2$$

כאשר $\text{rank}(A_k) = k$

$$A_k = U_k \Sigma_k V_k^T$$

(הקשר והקשר)

הקשר והקשר

הקשר והקשר

features in the d3'NE '3W'N-K in 2018
in the (JN) S P'YD-ENE P'YD

$V_i \in \mathbb{R}^k$ מידת המסה של ה- i -י
features - נקרא להם "מסות"

לרסה אחרת סכטר SVD

$$R \approx (U_K \sqrt{\Sigma_K}^T) (\sqrt{\Sigma_K} V_K^T) = \overset{M \times K}{U} \cdot \overset{K \times N}{V}$$

ה- K -מרחב \mathcal{H} של הפונקציות f_i מוגדר על ידי

$$r_i^u = \sum_{k=1}^K U_{u,k} \cdot V_{k,i}$$

$\lambda \lambda^2 \delta$ $\rho \gamma^2$ $\text{'L} \lambda \text{JCO}$ $\text{SV} - !$ SPARSE $2/\text{CN}$ R $\text{ON}' \lambda^2$

$\delta \lambda_N \lambda_2$

[illegible]

- "The absence of evidence is not the evidence of absence"

feature matrixes - הן מיוצגות כמטריצה

$$\begin{pmatrix} V & | & U \end{pmatrix}$$

$$(U, V) = \underset{U, V}{\operatorname{argmin}} \left[\sum_{(u,i) \in \gamma} \left(r_i^u - \sum_{k=1}^K U_{u,k} \cdot V_{k,i} \right)^2 \right]$$

GD על המטריצות

overfit מצד המשתמש

regularization

Maximum Margin Matrix Factorization = M M M F

U, V הם המטריצות של features והן מכילות את המידע של המשתמש והמוצרים

הן הן features והן הן המידע של המשתמש והמוצרים. הן הן המידע של המשתמש והמוצרים.

$$U, V = \underset{U, V}{\operatorname{argmin}} \left[\sum_{(u,i) \in \gamma} \left(r_i^u - \sum_{k=1}^K U_{u,k} \cdot V_{k,i} \right)^2 + \lambda_U \operatorname{tr}(U^T U) + \lambda_V \operatorname{tr}(V^T V) \right]$$